



AHMET YESEVİ ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

YAPAY ZEKA YÜKSEK LİSANS PROGRAMI

TEZSİZ YÜKSEK LİSANS DÖNEM PROJESİ

BULUT SİSTEMLERİNDE YAPAY ZEKA DESTEKLİ ANOMALİ TESPİTİ VE ERKEN UYARI SİSTEMİ

HAZIRLAYAN

Ömer Faruk UZKAL

(252195083)

DANIŞMAN ÖĞRETİM ÜYESİ

Prof. Dr. Erdal BEKİROĞLU

2026

ETİK İLKELERE UYGUNLUK BEYANI

Dönem proje yazma sürecinde bilimsel ve etik ilkelere uyduğumu, yararlandığım tüm kaynakları kaynak gösterme ilkelerine uygun olarak kaynakçada belirttiğimi ve bu bölümler dışındaki tüm ifadelerin şahsıma ait olduğunu beyan ederim.

Adı Soyadı

ÖMER FARUK UZKAL



BULUT SİSTEMLERİNDE YAPAY ZEKA DESTEKLİ ANOMALİ TESPİTİ VE ERKEN UYARI SİSTEMİ

Ömer Faruk UZKAL

AHMET YESEVİ ÜNİVERSİTESİ

YAPAY ZEKA YÜKSEK LİSANS PROGRAMI

2026

ÖZET

Bu çalışmada, bulut sistemlerinde ortaya çıkabilecek performans sapmalarını erken aşamada belirlemek amacıyla yapay zeka destekli bir anomali tespit ve erken uyarı sistemi geliştirilmiştir. Çalışmanın temel amacı; CPU kullanımı, RAM kullanımı, disk işlemleri, ağ trafiği, istek sayısı ve istek gecikmesi gibi sistem metriklerini veri temelli olarak analiz etmek, normal davranış örüntülerini modellemek ve bu örüntülerden sapmaları otomatik biçimde belirlemektir. Uygulama katmanında Python tabanlı analiz servisi, FastAPI tabanlı backend, Next.js tabanlı frontend ve Supabase destekli kimlik doğrulama yapısı birlikte kullanılmıştır. Veri ön işleme aşamasında şema doğrulama, zaman damgası dönüştürme, sayısal veri tipine zorlama, eksik kayıt temizliği ve mükerrer kayıt ayıklama işlemleri uygulanmıştır. Anomali tespit sürecinde gözetimsiz makine öğrenmesi yaklaşımı benimsenmiş ve ana model olarak Isolation Forest algoritması kullanılmıştır. Çalışmada model tercihi, One-Class SVM, Local Outlier Factor ve Z-Score yöntemleriyle yapılan karşılaştırmalı deneylerle desteklenmiştir. Ayrıca canlı telemetri akışı ve erken uyarı ekranı geliştirilerek sistemin yalnızca geçmiş veri üzerinde rapor üreten bir yapı değil, yeni gelen veri noktalarını izleyebilen bir prototip olduğu gösterilmiştir. Elde edilen bulgular, sistemin sekiz temel metrik üzerinde anomali tespiti üretebildiğini, sonuçları yorumlanabilir bir dashboard üzerinde sunabildiğini ve canlı erken uyarı mekanizmasıyla operasyonel izleme senaryosuna dönüştürülebildiğini göstermektedir.

Anahtar Kelimeler: anomali tespiti, bulut sistemleri, makine öğrenmesi, Isolation Forest, erken uyarı, zaman serisi, performans izleme

Danışman: Prof. Dr. Erdal BEKİROĞLU

AI-SUPPORTED ANOMALY DETECTION AND EARLY WARNING SYSTEM IN CLOUD SYSTEMS

Ömer Faruk UZKAL

AHMET YESEVI UNIVERSITY

ARTIFICIAL INTELLIGENCE MASTER'S PROGRAM

2026

ABSTRACT

This study presents an AI-supported anomaly detection and early warning system developed to identify performance deviations in cloud environments at an early stage. The main objective is to analyze system metrics such as CPU utilization, memory usage, disk operations, network traffic, request count and request latency, model normal behavior patterns and automatically detect deviations from these patterns. The implementation combines a Python-based analytics service, a FastAPI backend, a Next.js frontend and Supabase-supported authentication. The anomaly detection stage adopts an unsupervised machine learning approach and uses Isolation Forest as the primary model. The model selection is supported by comparative experiments with One-Class SVM, Local Outlier Factor and Z-Score methods. The findings show that the system can generate anomaly detection results across eight core metrics, present these results through an interpretable dashboard and support early warning through live telemetry simulation.

Keywords: anomaly detection, cloud systems, machine learning, Isolation Forest, early warning, time series, performance monitoring

Advisor: Prof. Dr. Erdal BEKİROĞLU

**AHMET YESEVİ
ÜNİVERSİTESİ**

İÇİNDEKİLER

ÖZET	iii
ABSTRACT	iv
İÇİNDEKİLER	v
ŞEKİLLER LİSTESİ	vi
TABLolar LİSTESİ	vii
SİMGELER VE KISALTMALAR	viii
BÖLÜM I GİRİŞ	1
1.1. Problem Durumu	1
1.2. Araştırmanın Amacı	1
1.3. Araştırmanın Önemi	1
1.4. Araştırmanın Kapsamı ve Sınırlılıkları	2
BÖLÜM II KAVRAMSAL ÇERÇEVE VE LİTERATÜR	3
2.1. Bulut Sistemlerinde Gözlemlenebilirlik	3
2.2. Anomali Tespiti Kavramı	3
2.3. Eşik Tabanlı ve Makine Öğrenmesi Tabanlı Yaklaşımlar	3
2.4. Isolation Forest Algoritması	3
2.5. Alternatif Algoritmalar	4
2.6. Gerçek Zamanlı Erken Uyarı Sistemleri	4
2.7. Literatür Bulgularının Çalışma Tasarımına Yansıması	4
BÖLÜM III YÖNTEM	7
3.1. Araştırma Modeli	7
3.2. Veri Seti Kapsamı ve Üretim Yapısı	7
3.3. Veri Ön İşleme ve Analiz Pipeline'ı	7
3.4. Modelleme ve Değerlendirme Ölçütleri	8
3.5. Deney Tasarımı ve Parametreleme	8
3.6. Veri Seti Güvenilirliği ve Kaynaklandırma	8
BÖLÜM IV SİSTEM TASARIMI VE UYGULAMA	11
4.1. Yazılım Mimarisi	11
4.2. Kullanıcı Arayüzü ve Ekranlar	12
4.3. Güvenlik ve Yetkilendirme	18
4.4. API, Endpoint ve Veri Akışı	18
4.5. Canlı Telemetri Karar Mantığı	18
4.6. Kullanıcı Arayüzünün Akademik Kanıt Değeri	19
BÖLÜM V BULGULAR	21
5.1. Isolation Forest Pipeline Bulguları	21
5.2. Karşılaştırmalı Algoritma Deneyleri	23
5.3. Metrik Bazlı Bulguların Yorumlanması	35
BÖLÜM VI TARTIŞMA	43
6.1. Model Tercihinin Değerlendirilmesi	43
6.2. False Positive, Concept Drift ve Ölçeklenebilirlik	44
6.3. Akademik Yorum	44
6.4. Geçerlilik ve Güvenilirlik Değerlendirmesi	44
6.5. Sektörel Uygulanabilirlik Tartışması	45
BÖLÜM VII SONUÇ VE ÖNERİLER	47
7.1. Sonuç	47
7.2. Literatüre ve Sektörel Uygulamalara Katkı	47
7.3. Öneriler	48
7.4. Özgün Katkının Değerlendirilmesi	48
KAYNAKÇA	49
EKLER	51

ŞEKİLLER LİSTESİ

Şekil 4.1. Kullanıcı giriş ekranı	12
Şekil 4.2. Gözetim merkezi ana ekranı	13
Şekil 4.3. CPU metrik detay grafiği	14
Şekil 4.4. Manuel analiz ve pipeline kontrol paneli	15
Şekil 4.5. Anomali tablo görünümü	16
Şekil 4.6. Dışa aktarma kontrolleri	17
Şekil 5.1. Algoritmalar arası karşılaştırmalı deney ekranı	33
Şekil 5.2. Canlı telemetri ve erken uyarı ekranı	34



TABLOLAR LİSTESİ

Tablo 5.1. Veri setleri ve kapsam bilgileri	21
Tablo 5.2. Isolation Forest model çıktıları	22
Tablo 5.3. CPU Kullanımı metriği karşılaştırmalı deney sonuçları	23
Tablo 5.4. Disk Yazma metriği karşılaştırmalı deney sonuçları	24
Tablo 5.5. Ağ Girişi metriği karşılaştırmalı deney sonuçları	25
Tablo 5.6. İstek Sayısı metriği karşılaştırmalı deney sonuçları	26
Tablo 5.7. İstek Gecikmesi metriği karşılaştırmalı deney sonuçları	27
Tablo 5.8. RAM Kullanımı metriği karşılaştırmalı deney sonuçları	28
Tablo 5.9. Isolation Forest güvenilirlik ve stabilite analizi	29
Tablo 5.10. McNemar anlamlılık testi p değerleri	30
Tablo 5.11. Derin öğrenme tabanlı autoencoder karşılaştırmalı sonuçları	31
Tablo 5.12. Sentetik concept drift stres testi sonuçları	32



SİMGELER VE KISALTMALAR

Kısaltma	Açıklama
API	Application Programming Interface
CI	Confidence Interval / Güven Aralığı
CSV	Comma Separated Values
IF	Isolation Forest
JWT	JSON Web Token
LOF	Local Outlier Factor
MLP	Multi-Layer Perceptron
NAB	Numenta Anomaly Benchmark
OC-SVM	One-Class Support Vector Machine
RLS	Row Level Security
Z-Score	Bir değerin ortalamadan standart sapma cinsinden uzaklığı



BÖLÜM I GİRİŞ

1.1. Problem Durumu

Bulut bilişim sistemleri, çok sayıda servis ve uygulamanın yüksek erişilebilirlik, ölçeklenebilirlik ve esneklik beklentileri ile çalıştığı dinamik ortamlardır. Bu yapılarda performans sorunları çoğu zaman tek bir log kaydıyla değil, CPU kullanımı, bellek tüketimi, disk işlemleri, ağ trafiği ve istek gecikmesi gibi metriklerdeki birlikte veya ardışık sapmalarla ortaya çıkar.

Sabit eşiklere dayalı izleme yaklaşımı pratik olmakla birlikte değişken iş yükleri altında esnek yorumlama gerektirir. Örneğin yoğun trafik döneminde yüksek CPU kullanımı olağan kabul edilebilirken, düşük trafik dönemindeki benzer artış sistemsel bir probleme işaret edebilir. Bu nedenle metriklerin kendi tarihsel davranışına göre değerlendirilmesi daha anlamlıdır.

Bu çalışma, bulut sistemlerinde ortaya çıkan performans sapmalarını veri temelli biçimde inceleyen, olağan dışı noktaları gözetimsiz öğrenme yöntemiyle belirleyen ve sonuçları kullanıcıya açıklanabilir bir arayüz üzerinden sunan bütünleşik bir prototip geliştirmektedir.

1.2. Araştırmanın Amacı

Araştırmanın amacı, bulut sistem metriklerini analiz ederek anomali tespiti ve erken uyarı üretebilen bir yazılım yapısı geliştirmektir. Bu amaç doğrultusunda veri hazırlama, modelleme, API sunumu, kullanıcı arayüzü, rol tabanlı erişim ve canlı telemetri akışı aynı sistem içerisinde ele alınmıştır.

Çalışma yalnızca bir makine öğrenmesi modeli kurmakla sınırlı değildir. Model çıktılarının anlaşılır biçimde görselleştirilmesi, karşılaştırmalı deneylerle model tercihinin desteklenmesi ve canlı veri akışı üzerinden erken uyarı üretiminin gösterilmesi hedeflenmiştir.

1.3. Araştırmanın Önemi

Bulut sistemlerinde hizmet kalitesinin korunması, performans sapmalarının erken fark edilmesine bağlıdır. Anomali tespiti, operasyon ekiplerine olay meydana geldikten sonra değil, olayın belirtileri olduğu sırada müdahale etme fırsatı sağlar.

Bu çalışmanın önemi, akademik algoritma değerlendirmesi ile uygulama geliştirme pratiğini birleştirmesidir. Isolation Forest modeli alternatif yöntemlerle karşılaştırılmış; sonuçlar yalnızca tablo olarak değil, çalışan bir dashboard ve canlı telemetri ekranı ile desteklenmiştir.

Araştırma; gözlemlenebilirlik, gözetimsiz öğrenme, erken uyarı, güvenli erişim ve kullanıcı arayüzü bileşenlerini tek proje çatısı altında birleştirerek literatüre uygulamalı bir örnek, sektörel kullanıma ise geliştirilebilir bir prototip sunmaktadır.

1.4. Araştırmanın Kapsamı ve Sınırlılıkları

Araştırmanın kapsamı, bulut sistemlerinde yaygın olarak izlenen performans metrikleriyle sınırlandırılmıştır. CPU, RAM, disk yazma, ağ girişi, istek sayısı ve istek gecikmesi metrikleri sistem sağlığına ilişkin farklı boyutları temsil ettiği için birlikte ele alınmıştır. Böylece yalnızca tek bir kaynak tüketimi değil, altyapı ve uygulama davranışını birlikte yansıtan çok yönlü bir izleme çerçevesi oluşturulmuştur.

Çalışmada kullanılan veri setleri, geçmiş zaman serisi kayıtları ve proje kapsamında uyarlanan RAM telemetri verilerinden oluşmaktadır. Bu nedenle çalışma, gerçek üretim ortamında kesintisiz veri toplayan tam ölçekli bir izleme platformu değil; veri işleme, modelleme, API sunumu, dashboard ve canlı telemetri simülasyonunu bir araya getiren uygulanabilir bir prototip olarak değerlendirilmelidir.

Etiketli olay kayıtlarının sınırlı olması, çalışmanın değerlendirme yaklaşımını doğrudan etkilemiştir. Bu nedenle model başarımı precision, recall ve F1-score gibi etiket gerektiren metriklerle değil; anomali oranı, çalışma süresi, karar kümeleri arasındaki benzerlik ve kullanıcıya sunulan operasyonel yorumlanabilirlik üzerinden ele alınmıştır.

Bu sınırlılık, çalışmanın değerini azaltmamakta; aksine bulut sistemlerinde sık karşılaşılan etiket eksikliği problemini görünür kılmaktadır. Üretim ortamlarında her performans sapmasının doğru sınıflandırılmış olay etiketiyle birlikte tutulması çoğu zaman mümkün olmadığından, gözetimsiz yöntemlerin uygulanabilirliği pratik açıdan önem taşımaktadır.

BÖLÜM II KAVRAMSAL ÇERÇEVE VE LİTERATÜR

2.1. Bulut Sistemlerinde Gözlemlenebilirlik

Gözlemlenebilirlik, bir sistemin iç durumunun dışarıdan toplanan metrik, log ve izler aracılığıyla anlaşılabilmesidir. Bulut sistemlerinde kaynaklar dinamik olarak değiştiği için gözlemlenebilirlik yalnızca teknik bir izleme faaliyeti değil, hizmet sürekliliğini koruyan bir karar destek sürecidir.

Bu çalışma metrik temelli gözlemlenebilirlik yaklaşımını benimsemektedir. CPU, RAM, disk, ağ, istek sayısı ve istek gecikmesi metrikleri altyapı ve uygulama performansının temel göstergeleri olarak ele alınmıştır.

2.2. Anomali Tespiti Kavramı

Anomali tespiti, veri kümesinin genel davranışından belirgin biçimde ayrılan gözlemleri bulmayı amaçlar. Bulut sistemlerinde anomali yalnızca yüksek değer anlamına gelmez; beklenmeyen düşüş, ani dalgalanma, süreklilik gösteren sapma veya bağlamsal uyumsuzluk da anomali olarak değerlendirilebilir.

Etiketli olay verisinin sınırlı olduğu ortamlarda gözetimsiz yöntemler öne çıkar. Bu yöntemler, sistemin geçmiş davranışından normal örüntüyü çıkarmaya çalışır ve bu örüntünün dışındaki noktaları aday anomali olarak işaretler.

2.3. Eşik Tabanlı ve Makine Öğrenmesi Tabanlı Yaklaşımlar

Eşik tabanlı yöntemler anlaşılır ve hızlıdır; ancak sistem davranışındaki dönemsel değişimleri yakalamakta zorlanır. Sabit eşik yaklaşımı, trafik artışı gibi beklenen durumlarda yanlış alarm üretebilir veya düşük trafik dönemindeki anlamlı sapmaları kaçırabilir.

Makine öğrenmesi tabanlı yöntemler, verideki dağılımı ve olağan davranış örüntüsünü dikkate alır. Bu nedenle özellikle değişken yük altında çalışan bulut sistemlerinde daha esnek bir yaklaşım sunar. Ancak bu yöntemlerde parametre seçimi, veri kalitesi ve modelin güncelliği sonuçları doğrudan etkiler.

2.4. Isolation Forest Algoritması

Isolation Forest, anomalilerin normal gözlemlere göre daha kolay izole edilebileceği varsayımına dayanır. Rastgele ağaçlar oluşturulur ve her gözlemin izole edilmesi için gereken yol uzunluğu değerlendirilir. Daha kısa yol uzunluğu, gözlemin daha aykırı davranış gösterdiğine işaret eder.

Bu algoritmanın temel avantajı, yoğunluk veya mesafe matrisi hesaplamadan çalışabilmesidir. Bu durum özellikle büyük metrik dosyalarında çalışma süresini makul düzeyde tutar. Ayrıca etiketli veriye ihtiyaç duymaması, çalışma kapsamındaki veri yapısıyla uyumludur.

Isolation Forest'in tercih edilme nedeni yalnızca popüler olması değildir. Karşılaştırmalı deneyler, bu yöntemin alarm yoğunluğu ve çalışma süresi açısından dengeli sonuç verdiğini göstermiştir. OC-SVM bazı metriklerde aşırı alarm üretirken, Z-Score yalnızca global uç değerleri yakalayabilmiş, LOF ise bazı metriklerde karar örtüşmesi bakımından sınırlı kalmıştır.

2.5. Alternatif Algoritmalar

One-Class SVM, normal veri dağılımını karar sınırı ile temsil etmeye çalışır. Teorik olarak güçlü olmasına rağmen çekirdek fonksiyonu ve parametre seçimi nedeniyle veri boyutu büyüdükçe hesaplama maliyeti artabilir. Bu çalışmada bazı metriklerde yüksek false positive eğilimi göstermiştir.

Local Outlier Factor, bir noktanın yerel yoğunluğunu komşularıyla karşılaştırır. Yerel yapıların önemli olduğu veri kümelerinde yararlı olabilir; fakat komşuluk temelli hesaplama büyük veri kümelerinde maliyetli hale gelebilir.

Z-Score yöntemi hızlı ve açıklanabilir bir istatistiksel yaklaşımdır. Buna karşılık yalnızca ortalamadan standart sapma cinsinden uzaklığı ölçtüğü için trend içindeki bağlamsal anomalileri kaçırabilir. Bu nedenle erken uyarı ekranında pratik bir kontrol mekanizması olarak, ana model değerlendirmesinde ise karşılaştırma yöntemi olarak kullanılmıştır.

2.6. Gerçek Zamanlı Erken Uyarı Sistemleri

Gerçek zamanlı erken uyarı sistemleri, yeni gelen veri noktasını bekletmeden değerlendirir. Bu tür sistemlerde amaç yalnızca geçmiş olayları raporlamak değil, sistem davranışında risk belirtisi oluştuğunda kullanıcıyı mümkün olduğunca erken bilgilendirmektir.

Bu projede canlı telemetri ekranı, simüle edilen veri noktalarını backend'e gönderir. Backend kayan pencere üzerinde sapma hesabı yapar ve eşik aşıldığında alarm üretir. Bu akış, offline analiz pipeline'ını operasyonel erken uyarı senaryosuyla tamamlamaktadır.

2.7. Literatür Bulgularının Çalışma Tasarımına Yansıması

Literatürde anomali tespit yöntemleri genel olarak istatistiksel yaklaşımlar, yoğunluk temelli yaklaşımlar, sınır temelli yaklaşımlar ve ağaç temelli gözetimsiz yöntemler altında değerlendirilmektedir. Bu ayrım, çalışmada kullanılan algoritma setinin belirlenmesinde temel alınmıştır. Z-Score istatistiksel yaklaşımı, LOF yoğunluk temelli yaklaşımı, OC-SVM sınır temelli yaklaşımı ve Isolation Forest ağaç temelli yaklaşımı temsil etmektedir.

Bu sınıflandırma sayesinde karşılaştırmalı deneyler farklı varsayımlara dayanan yöntemleri aynı veri kümeleri üzerinde birlikte incelemiştir. Böylece model tercihinin gerekçesi hem literatürdeki kuramsal dayanaklara hem de çalışan yazılım üzerinden elde edilen deneysel sonuçlara dayandırılmıştır.

Literatürde gerçek zamanlı anomali tespit sistemleri değerlendirilirken veri setinin niteliği, modelin karar üretme biçimi, alarm yoğunluğu, açıklanabilirlik ve operasyonel entegrasyon birlikte ele alınmaktadır. Bu akademik çerçeve, çalışmada dashboard, dışa aktarma, canlı telemetri ve alarm listesi gibi kullanıcıya dönük bileşenlerin model çıktısının tamamlayıcı parçası olarak tasarlanmasını desteklemiştir.

Bu projede model seçimi, farklı metrik türlerinde üretilen alarm yoğunluğu, karar örtüşmesi, çalışma süresi ve kullanıcıya sunulan çıktıların yorumlanabilirliği birlikte değerlendirilerek yapılmıştır. Elde edilen deneysel sonuçlar, kullanılan yöntemlerin bulut performans metrikleri üzerindeki davranışını görünür kılmış ve Isolation Forest tercihinin proje verisi üzerinde üretilen bulgularla desteklenmesini sağlamıştır.

Çalışan yazılım çıktılarının rapora dahil edilmesi, kavramsal çerçeve ile uygulama bölümü arasında güçlü bir bağ kurmaktadır. Veri işleme pipeline'ı, model karşılaştırmaları, dashboard ekranları, metrik detay grafikleri ve canlı telemetri akışı aynı araştırma tasarımının birbirini tamamlayan bileşenleri olarak ele alınmıştır.

Bu yapı, çalışmanın bulut operasyonları bağlamında değerlendirilebilecek uygulamalı bir anomali tespit ve erken uyarı prototipi sunduğunu göstermektedir. Sistem, literatürdeki gözetimsiz anomali tespit yaklaşımlarını modern web tabanlı izleme arayüzüyle birleştiren tamamlanmış ve incelenebilir bir örnek ortaya koymaktadır.

Literatür bulgularının çalışma tasarımına yansıyan bir diğer yönü, tek metrik yerine çoklu metrik yaklaşımının tercih edilmesidir. CPU, RAM, ağ, disk, istek sayısı ve istek gecikmesi metrikleri farklı sistem davranışlarını temsil ettiği için model sonuçlarının bu metrikler üzerinde birlikte raporlanması, çalışmanın genellenebilirlik değerlendirmesini güçlendirmiştir.

Bulut sistemlerinde gözlemlenen performans olayları çoğu zaman tek bir göstergeyle açıklanmaz. CPU artışı istek gecikmesiyle, ağ trafiği disk yazma davranışıyla, RAM kullanımı ise uygulama yoğunluğu ile birlikte anlam kazanabilir. Bu nedenle çalışmada metriklerin ayrı ayrı işlenmesiyle birlikte sonuçların bütüncül olarak yorumlanmasına da önem verilmiştir.

Literatürde öne çıkan açıklanabilirlik ve izlenebilirlik gereksinimi, bu çalışmada model çıktılarının kullanıcı arayüzüyle desteklenmesiyle karşılanmıştır. Anomali sayıları, oranlar, karar benzerlikleri ve çalışma süreleri yalnızca tablo halinde verilmemiş; aynı zamanda dashboard ve metrik detay ekranlarıyla kullanıcı tarafından incelenebilir hale getirilmiştir.

Model karşılaştırma yaklaşımı, çalışmanın bilimsel tutarlılığını güçlendiren ana tasarım kararlarından biridir. Aynı veri setleri üzerinde farklı algoritmaların çalıştırılması, yöntemlerin alarm üretme eğilimlerini doğrudan karşılaştırmayı mümkün kılmıştır. Bu yapı, seçilen modelin proje bağlamında neden uygun olduğunu açık biçimde ortaya koymaktadır.

Erken uyarı bileşeninin çalışmaya dahil edilmesi, literatürdeki gerçek zamanlı izleme gereksiniminin uygulama tarafındaki karşılığını oluşturmaktadır. Canlı telemetri ekranı, yeni veri noktalarının sisteme eklenmesini ve alarm mantığının çalışmasını görünür kılarak araştırmanın uygulamalı niteliğini güçlendirmektedir.

Bu nedenle kavramsal çerçeve, yöntem ve uygulama bölümleri birbirinden bağımsız parçalar olarak değil, aynı araştırma hedefini destekleyen bütünleşik katmanlar olarak tasarlanmıştır. Literatürden gelen modelleme ilkeleri, yöntem bölümündeki deney protokolüne; deney çıktıları ise sistem tasarımı ve kullanıcı arayüzü bölümlerine doğrudan yansıtılmıştır.



BÖLÜM III YÖNTEM

3.1. Araştırma Modeli

Çalışma uygulamalı yazılım geliştirme ve deneysel değerlendirme yaklaşımını birlikte kullanmaktadır. Veri kaynakları belirlenmiş, ön işleme pipeline'ı kurulmuş, Isolation Forest modeli uygulanmış ve alternatif algoritmalarla karşılaştırmalı deneyler yapılmıştır.

Yazılım tarafında FastAPI backend, Next.js frontend ve Supabase tabanlı kimlik doğrulama yapısı birlikte kullanılmıştır. Bu yapı, analiz çıktılarının yalnızca dosya düzeyinde kalmasını engelleyerek kullanıcı arayüzü üzerinden incelenebilir hale getirmiştir.

3.2. Veri Seti Kapsamı ve Üretim Yapısı

Çalışmada kullanılan veriler CSV formatındadır. CPU, disk, ağ, istek sayısı ve istek gecikmesi metrikleri zaman damgası ve değer sütunlarından oluşmaktadır. RAM telemetri dosyası ise çok sütunlu sistem ölçümlerinden oluşmakta, pipeline içinde bellek metriklerine dönüştürülmektedir.

Veri toplama süreleri metrikten metriğe değişmektedir. CPU verisi yaklaşık 62 günlük geniş bir pencereyi temsil ederken, disk verisi yaklaşık 16 gün, ağ ve istek metrikleri yaklaşık 14 gün izleme süresi sunmaktadır. RAM verisi ise sentetik zaman damgası ile yaklaşık 33 saatlik daha sık örneklenen bir telemetri yapısına uyarlanmıştır.

Çalışmanın 2026 yılında geliştirilmiş olması, veri setlerindeki 2014 tarihleriyle çelişmemektedir. Bu tarihler, kullanılan açık zaman serisi kayıtlarının ölçüm zaman damgalarını göstermektedir. Dolayısıyla raporda 2014 olarak verilen zaman aralıkları veri kaynağının toplama dönemini, 2026 yılı ise proje geliştirme ve raporlama dönemini ifade etmektedir.

Bu çeşitlilik model değerlendirmesi açısından önemlidir. Farklı kayıt sayısı, farklı örnekleme süresi ve farklı dağılım yapısına sahip metrikler, algoritmanın yalnızca tek veri tipinde değil, birden fazla operasyonel durumda nasıl davrandığını gözlemlemeye olanak tanır.

3.3. Veri Ön İşleme ve Analiz Pipeline'ı

Veri ön işleme aşamasında şema doğrulama, zaman damgası dönüştürme, sayısal tipe zorlama, eksik kayıt temizleme ve mükerrer kayıt ayıklama adımları uygulanmıştır. Bu adımlar modelin hatalı veya eksik veri nedeniyle yanıltıcı sonuç üretmesini azaltmayı hedefler.

Pipeline her metrik için bağımsız çalışır. Böylece CPU, RAM, disk ve ağ gibi ölçekleri farklı olan metrikler aynı model içinde karıştırılmaz. Her metrik kendi dağılımı içinde değerlendirilir ve sonuçlar özet, grafik verisi, anomali listesi ve dışa aktarılabilir CSV çıktısı olarak saklanır.

3.4. Modelleme ve Değerlendirme Ölçütleri

Ana model olarak Isolation Forest kullanılmıştır. Modelin ürettiği anomali sayısı, toplam kayıt sayısına oranlanmış ve dashboard üzerinde yorumlanabilir hale getirilmiştir. Karşılaştırmalı deneylerde OC-SVM, LOF ve Z-Score yöntemleri aynı veri kümeleri üzerinde çalıştırılmıştır.

Değerlendirme ölçütleri anomali sayısı, anomali oranı, çalışma süresi ve Isolation Forest ile Jaccard benzerliğidir. Etiketli veri sınırlı olduğu için precision ve recall gibi klasik sınıflandırma metrikleri kullanılmamıştır. Bunun yerine modellerin karar kümelerinin ne ölçüde örtüştüğü ve çalışma maliyetleri incelenmiştir.

3.5. Deney Tasarımı ve Parametreleme

Deney tasarımında tüm algoritmalar aynı veri kümeleri üzerinde çalıştırılmıştır. Bu tercih, yöntemler arasındaki farkların veri kaynağı farklılığından değil, algoritmaların karar mekanizmasından kaynaklanmasını sağlar. Her veri seti için zaman damgası, değer ve metrik adı standartlaştırılmış; RAM verisinde ise çoklu sütun yapısından ayrı metrik serileri türetilmiştir.

Isolation Forest için kontaminasyon oranı düşük tutulmuş ve modelin operasyonel olarak yönetilebilir sayıda alarm üretmesi hedeflenmiştir. Bulut izleme bağlamında çok yüksek alarm oranı, kullanıcıların alarm yorgunluğu yaşamasına neden olabilir. Bu nedenle modelin yalnızca teknik olarak sapma yakalaması değil, üretilebilir alarm hacminin izlenebilir olması da değerlendirilmiştir.

OC-SVM ve LOF yöntemleri aynı veri üzerinde karşılaştırma amacıyla uygulanmıştır. OC-SVM'nin bazı metriklerde yüksek alarm üretmesi, parametre duyarlılığının ve veri dağılımına bağlı karar sınırlarının önemini göstermiştir. LOF ise yerel yoğunluk ilişkilerini dikkate aldığı için bazı metriklerde daha kontrollü sonuçlar vermiş, bazı metriklerde ise Isolation Forest ile düşük örtüşme göstermiştir.

Z-Score yöntemi hızlı ve açıklanabilir bir referans yöntem olarak kullanılmıştır. Ancak zaman serilerinde bağlamsal sapmaları yakalama gücü sınırlı olduğundan ana model olarak tercih edilmemiştir. Bu deney tasarımı, hocanın talep ettiği algoritma karşılaştırmasını doğrudan bulgular bölümüne taşıyacak şekilde planlanmıştır.

3.6. Veri Seti Güvenilirliği ve Kaynaklandırma

Kullanılan CSV dosyalarının her biri kaynakçada veri seti notu olarak belirtilmiştir. CPU, disk, ağ, istek sayısı ve istek gecikmesi verileri Numenta Anomaly Benchmark veri yapısıyla uyumlu zaman serisi kayıtlarıdır. RAM telemetri dosyası ise proje kapsamında analiz pipeline'ına uyarlanmış ve sistem belleğiyle ilişkili üç ayrı metrik üretmek için kullanılmıştır.

Veri setlerinin tarih aralıkları ve kayıt sayıları yöntem bölümünde açıkça verilmiştir. Bu bilgi, model sonuçlarının hangi süre ve veri büyüklüğü üzerinde üretildiğini göstermesi bakımından önemlidir. Örneğin CPU verisi 18.050 kayıtla en geniş veri penceresini sunarken, RAM verisi daha kısa fakat daha sık örneklenen bir telemetri yapısına sahiptir.

Veri üretim yapısındaki farklılıklar, model çıktılarının yorumlanmasında dikkate alınmıştır. Kayıt sayısı yüksek olan metriklerde anomali sayısı doğal olarak artabilir; bu nedenle yalnızca mutlak anomali sayısına bakmak yeterli değildir. Bulgular bölümünde anomali oranı ve karşılaştırmalı karar benzerliği birlikte değerlendirilmiştir.

Çalışma, açık veri setleri ve proje kapsamındaki işlenmiş CSV dosyaları üzerine kurulduğu için tekrarlanabilirlik açısından avantaj sağlamaktadır. Aynı dosyalar ve aynı analiz pipeline'ı kullanıldığında model çıktılarının yeniden üretilebilmesi, akademik doğrulanabilirlik açısından önemli bir katkıdır.

Veri setlerinin güvenilirliği, aynı ön işleme ve analiz adımlarının tekrar çalıştırıldığında tutarlı sonuçlar üretmesiyle desteklenmiştir. Bu nedenle veri okuma, zaman sıralama, sayısal tipe dönüştürme, eksik kayıt temizleme ve metrik bazlı ayrıştırma adımları standart bir pipeline içinde yürütülmüştür.

Tüm algoritmaların aynı veri kaynakları üzerinde çalıştırılması, karşılaştırmalı deneylerin adil ve tekrar edilebilir olmasını sağlamıştır. Isolation Forest, OC-SVM, LOF, Z-Score, MLP Autoencoder ve Temporal MLP Autoencoder yöntemleri aynı metrik serileri üzerinde değerlendirildiği için sonuçlar yöntem davranışını karşılaştırmaya uygun bir deney zemini sunmaktadır.

Pipeline çıktıları yalnızca sayısal sonuç olarak bırakılmamış; özet istatistikler, grafik verileri, anomali listeleri ve dışa aktarılabilir CSV çıktıları halinde uygulama katmanına aktarılmıştır. Böylece yöntem bölümünde tanımlanan veri işleme süreci, sistem tasarımı ve bulgular bölümlerinde izlenebilir biçimde devam etmektedir.

Bu düzen, çalışmanın akademik tekrar üretilebilirliğini ve yazılım çıktılarıyla doğrulanabilirliğini güçlendirmektedir. Veri kaynaklarının açık biçimde belirtilmesi, deney parametrelerinin raporlanması ve sonuçların uygulama ekranlarında gösterilmesi, araştırma sürecinin bütünlüğünü destekleyen temel unsurlar olarak değerlendirilmiştir.

Veri setlerinin her biri farklı sistem davranışını temsil ettiği için değerlendirme sürecinde metriklerin kendi bağlamı korunmuştur. CPU kullanım oranı işlem yükünü, disk yazma metriği depolama hareketliliğini, ağ girişi trafik yoğunluğunu, istek sayısı uygulama talebini, istek gecikmesi hizmet yanıt süresini ve RAM metrikleri bellek durumunu temsil etmektedir.

Bu ayırım, tüm verilerin tek bir genel ölçeğe indirgenmesi yerine her metrik serisinin kendi dağılımı içinde değerlendirilmesini sağlamıştır. Böylece model çıktıları, ilgili performans göstergesinin doğal davranış örüntüsüyle birlikte yorumlanabilmiştir.

Analiz pipeline'ı, ham CSV dosyalarından başlayarak frontend ekranlarında görülen sonuçlara kadar takip edilebilir bir veri akışı oluşturur. Bu akış içinde veri temizleme, model çalıştırma, sonuç saklama, API üzerinden sunma ve kullanıcı arayüzünde gösterme adımları birbirini tamamlayan süreçlerdir.

Bu süreçlerin açık biçimde tanımlanması, çalışmanın hem yazılım mühendisliği hem de akademik raporlama açısından güçlü bir temel sunmasını sağlamaktadır. Projede elde edilen sonuçlar, yalnızca tek seferlik deney çıktısı olarak değil, aynı veri kaynakları ve aynı işlem adımlarıyla yeniden üretilebilecek analiz sonuçları olarak konumlandırılmıştır.

Veri güvenilirliği yaklaşımı aynı zamanda bulgular bölümündeki tabloların yorumlanmasını da destekler. Her tablo, belirli bir metrik ve algoritma kombinasyonundan üretilen çıktıya dayandığı için okuyucu model davranışını veri seti kapsamı, kayıt sayısı ve üretilen anomali oranı ile birlikte değerlendirebilir.



BÖLÜM IV SİSTEM TASARIMI VE UYGULAMA


4.1. Yazılım Mimarisi

Sistem veri ve analiz katmanı, backend API katmanı, frontend kullanıcı arayüzü ve kimlik doğrulama katmanından oluşmaktadır. Analiz katmanı ham CSV verilerini okur ve anomali çıktıları üretir. Backend bu çıktıları API endpointleri aracılığıyla sunar. Frontend ise sonuçları dashboard, detay sayfası, karşılaştırma ekranı ve canlı telemetri ekranı olarak kullanıcıya gösterir.

Canlı veri akışı için backend tarafında telemetri endpointleri tanımlanmıştır. Frontend simülasyon sırasında yeni veri noktalarını bu endpointlere gönderir. Backend kayan pencere yaklaşımıyla sapmayı hesaplar ve uyarı üretir. Bu yapı, erken uyarı kavramının uygulama içinde çalışır bir bileşene dönüşmesini sağlamaktadır.




4.2. Kullanıcı Arayüzü ve Ekranlar




Şekil 4.1. Kullanıcı giriş ekranı

Bu ekran sistemin kimlik doğrulama adımını göstermektedir. Kullanıcı e-posta ve şifre bilgisiyle giriş yapar; böylece analiz sonuçları yetkisiz erişime kapalı tutulur.




Şekil 4.2. Gözetim merkezi ana ekranı

Ana ekran, desteklenen metriklerin özet durumunu sunar. Kullanıcı kayıt sayısı, anomali oranı ve sistem profili üzerinden hangi metriğin ayrıntılı inceleneceğine karar verebilir.




Şekil 4.3. CPU metrik detay grafiği

Metrik detay ekranı, zaman serisi üzerindeki normal ve olağan dışı noktaların birlikte görülmesini sağlar. Grafik, model çıktısının kullanıcı tarafından yorumlanabilir hale gelmesini destekler.




Şekil 4.4. Manuel analiz ve pipeline kontrol paneli

Bu panel, yetkili kullanıcının analiz pipeline'ını manuel olarak tetikleyebilmesini sağlar. Böylece veri güncellendiğinde model çıktıları tekrar üretilebilir.



Şekil 4.5. Anomali tablo görünümü

Tablo görünümü, tespit edilen anomalilerin zaman, değer ve risk bağlamında incelenmesini sağlar. Kullanıcı yalnızca grafiğe değil, satır bazlı olay listesine de erişir.



Şekil 4.6. Dışa aktarma kontrolleri

Dışa aktarma kontrolleri ham veri ve anomali sonuçlarının CSV olarak alınabilmesini sağlar. Bu özellik, analiz çıktılarının raporlama ve yeniden inceleme süreçlerinde kullanılmasına olanak tanır.

4.3. Güvenlik ve Yetkilendirme

Kimlik doğrulama Supabase Auth ile sağlanmıştır. Kullanıcının oturum bilgisi frontend ve backend arasında güvenli biçimde taşınır. Rol tabanlı yetkilendirme sayesinde pipeline çalıştırma ve alarm temizleme gibi kritik işlemler yalnızca yetkili kullanıcılar tarafından yapılabilir.

Bu güvenlik yaklaşımı, anomali tespit sisteminin yalnızca teknik bir analiz aracı değil, gerçek kullanıcı rolleriyle çalışabilecek bir prototip olduğunu göstermektedir. Gizli servis anahtarları ve şifreler rapor metnine dahil edilmemiştir.

4.4. API, Endpoint ve Veri Akışı

Sistemde analiz çıktıları backend API üzerinden sunulmaktadır. Dashboard ekranı özet metrikleri, metrik detay ekranı grafik ve anomali satırlarını, karşılaştırma ekranı ise farklı algoritmaların deney sonuçlarını API yanıtları üzerinden almaktadır. Böylece kullanıcı arayüzü sabit metin veya görselden değil, proje uygulamasının ürettiği gerçek sonuçlardan beslenmektedir.

Canlı telemetri tarafında frontend belirli aralıklarla yeni ölçüm noktası üretir ve backend'e gönderir. Backend bu noktayı son gözlemlerden oluşan kayan pencereyle birlikte değerlendirir. Eşik ve sapma koşulları sağlandığında alarm nesnesi oluşturulur ve aktif uyarı listesine eklenir.

Bu veri akışı, erken uyarı yapısının yalnızca teorik bir iddia olmadığını göstermektedir. Kullanıcı canlı ekranda yeni veri noktalarının grafiğe eklendiğini, alarm listesinin güncellendiğini ve sistemin hangi değer üzerinden uyarı verdiğini izleyebilmektedir.

4.5. Canlı Telemetri Karar Mantığı

Canlı telemetri modülü, üretim ortamındaki akış mantığını küçük ölçekli ve kontrol edilebilir bir senaryoyla temsil eder. Her yeni veri noktası, geçmiş gözlemlerden oluşan pencere içinde değerlendirilir. Ani yükseliş, düşüş veya beklenmeyen sapma oluştuğunda sistem uyarı üretir.

Bu yaklaşımda erken uyarının amacı kesin arıza teşhisi koymak değildir. Uyarı, operasyon ekibinin dikkatini incelemeye değer bir duruma yönelten sinyal olarak tasarlanmıştır. Bu nedenle alarm kartlarında zaman, metrik, değer ve risk düzeyi birlikte sunulur.

Canlı sistem entegrasyonu genişletildiğinde bu yapı Prometheus, mesaj kuyruğu veya zaman serisi veritabanı gibi kaynaklarla beslenebilir. Prototipte geliştirilen endpoint ve arayüz yapısı, bu tür genişletmeler için temel mimari iskeleti sağlamaktadır.

4.6. Kullanıcı Arayüzünün Akademik Kanıt Değeri

Ekran görüntüleri, yalnızca uygulamanın görsel tasarımını göstermek için kullanılmamıştır. Her görsel, sistemin belirli bir akademik ve teknik iddiasını kanıtlayan çıktı olarak ele alınmıştır. Giriş ekranı yetkilendirmeyi, dashboard izleme kapsamını, metrik grafiği model yorumlanabilirliğini, karşılaştırma ekranı algoritma değerlendirmesini ve canlı telemetri ekranı erken uyarı yapısını göstermektedir.

Bu nedenle şekil açıklamalarında kullanıcının ekranda ne gördüğü, bu ekranın proje açısından neyi kanıtladığı ve görselin hangi veri/model çıktısından beslendiği ayrıca ifade edilmiştir. Bu düzenleme, görsellerin rapor içinde bağımsız ve anlaşılır akademik kanıt unsurları olmasını sağlar.

Kullanıcı arayüzü tasarımı, teknik sonuçların farklı kullanıcı rolleri tarafından incelenebilmesini hedefler. Dashboard yapısı, modelin ürettiği sayısal çıktıları grafik, tablo, alarm listesi ve özet göstergelerle destekleyerek operasyonel karar desteğine dönüştürür.

Metrik detay ekranları, model çıktısının zaman eksenindeki bağlamını görünür hale getirir. Kullanıcı hangi noktanın anomali olarak işaretlendiğini, bu noktanın normal davranıştan nasıl ayrıldığını ve alarmin hangi metrik üzerinde oluştuğunu aynı ekranda değerlendirebilir.

Karşılaştırmalı deney ekranı, algoritma sonuçlarının uygulama içinde izlenebilir biçimde sunulduğunu göstermektedir. Bu ekran sayesinde Isolation Forest, OC-SVM, LOF, Z-Score ve eklenen autoencoder yaklaşımlarının alarm sayısı, oran, çalışma süresi ve karar benzerliği açısından ürettiği sonuçlar kullanıcıya açık biçimde aktarılmaktadır.

Canlı telemetri ekranı, erken uyarı mantığının çalışan yazılım üzerinde nasıl uygulandığını göstermektedir. Yeni veri noktalarının grafik akışına eklenmesi, alarm listesinin güncellenmesi ve sistemin uyarı üretme gerekçesinin görünür olması, prototipin operasyonel kullanım değerini güçlendirmektedir.

Dışa aktarma işlevleri, analiz sonuçlarının raporlama ve yeniden inceleme süreçlerinde kullanılmasını sağlar. Bu özellik, çalışmanın yalnızca ekran üzerinde izlenen bir uygulama değil, akademik ve operasyonel değerlendirmeye veri sağlayan bir sistem olarak tasarlandığını göstermektedir.

Bu yönüyle kullanıcı arayüzü, veri işleme ve modelleme katmanlarının somut çıktıya dönüştüğü kanıt alanıdır. Geliştirilen ekranlar, çalışmanın yazılım uygulaması ile akademik raporlamasını aynı bütünlük içinde birleştirmektedir.

Arayüzde yer alan özet kartlar, metriklerin hızlı biçimde karşılaştırılmasına yardımcı olur. Kullanıcı toplam kayıt sayısını, anomali sayısını ve anomali oranını aynı bakışta görerek hangi metrik üzerinde ayrıntılı inceleme yapacağına karar verebilir.

Metrik detay grafikleri, anomali noktalarının zaman serisi üzerindeki konumunu gösterdiği için model çıktısının yorumlanabilirliğini artırır. Bu görselleştirme, sayısal sonuçların zaman bağlamıyla birlikte değerlendirilmesini sağlar ve erken uyarı kararının hangi veri örüntüsünden beslendiğini açık hale getirir.

Alarm tablosu, tespit edilen olağan dışı gözlemlerin zaman, değer ve risk bağlamında incelenmesine olanak tanır. Böylece kullanıcı, yalnızca grafikteki işaretleri değil, olay bazlı kayıtları da değerlendirebilir ve gerekli durumlarda dışa aktarma işlevleriyle bu kayıtları raporlama sürecine taşıyabilir.

Karşılaştırmalı deney ekranının uygulama içinde yer alması, model seçiminin raporda anlatılan soyut bir karar olmadığını; çalışan sistem üzerinde üretilen deney sonuçlarıyla desteklendiğini göstermektedir. Bu ekran, çalışmanın akademik bulguları ile yazılım çıktıları arasında doğrudan bağ kurmaktadır.

Canlı telemetri bileşeni ise prototipin erken uyarı mantığını kullanıcı tarafından gözlemlenebilir hale getirir. Simülasyon sırasında yeni veri noktalarının üretilmesi, backend'e gönderilmesi, kayan pencere içinde değerlendirilmesi ve alarm listesine yansması, sistemin uçtan uca çalıştığını göstermektedir.

Bu tasarım kararları, kullanıcı arayüzünü raporun tamamlayıcı bir görsel unsuru olmaktan çıkarıp araştırma bulgularının doğrulanabildiği uygulamalı bir kanıt alanına dönüştürmektedir. Böylece proje, modelleme, sistem geliştirme ve operasyonel yorumlanabilirlik boyutlarını aynı yazılım çıktısı içinde birleştirmektedir.

BÖLÜM V BULGULAR

5.1. Isolation Forest Pipeline Bulguları

Pipeline çıktıları, her metrikte düşük yoğunluklu fakat operasyonel olarak incelenebilir anomali kümeleri üretildiğini göstermektedir. Bu bulgu, modelin alarm üretimini kontrol altında tuttuğunu ve dashboard üzerinde yönetilebilir bir olay hacmi sunduğunu göstermektedir.

Tablo 5.1. Veri setleri ve kapsam bilgileri

Metrik	CSV dosyası	Kayıt	Tarih / üretim bilgisi	Örnekleme
CPU Kullanımı	cpu_utilization_asg_misconfiguration.csv	18.050	2014-05-14 01:14 - 2014-07-15 17:19	5 dakika
Disk Yazma	ec2_disk_write_bytes_1ef3de.csv	4.730	2014-03-01 17:34 - 2014-03-18 03:39	5 dakika
Ağ Girişi	ec2_network_in_257a54.csv	4.032	2014-04-10 00:04 - 2014-04-24 00:09	5 dakika
İstek Gecikmesi	ec2_request_latency_system_failure.csv	4.032	2014-03-07 03:41 - 2014-03-21 03:41	5 dakika
İstek Sayısı	elb_request_count_8c0756.csv	4.032	2014-04-10 00:04 - 2014-04-24 00:39	5 dakika
RAM Kullanımı	ram_telemetry.csv	2.000	Sentetik zaman damgası ile yaklaşık 33 saat	1 dakika
RAM Kullanılabilir	ram_telemetry.csv	2.000	Sentetik zaman damgası ile yaklaşık 33 saat	1 dakika
RAM Boş	ram_telemetry.csv	2.000	Sentetik zaman damgası ile yaklaşık 33 saat	1 dakika

Tablolarda görülen 2014 tarihleri, kullanılan açık zaman serisi veri setlerindeki ölçüm zaman damgalarını göstermektedir. Projenin geliştirme ve raporlama yılı 2026'dır. RAM telemetri dosyasında doğrudan zaman damgası bulunmadığı için bu veri, analiz pipeline'ında sentetik zaman eksenine uyarlanmıştır.

Tablo 5.2. Isolation Forest model çıktıları

Metrik	Kayıt	Anomali	Oran
CPU Kullanımı	18.050	169	%0,94
Disk Yazma	4.730	46	%0,97
Ağ Girişi	4.032	41	%1,02
İstek Gecikmesi	4.032	39	%0,97
İstek Sayısı	4.032	41	%1,02
RAM Kullanımı	2.000	19	%0,95
RAM Kullanılabilir	2.000	20	%1,00
RAM Boş	2.000	20	%1,00

Tablo 5.2'deki oranlar, Isolation Forest modelinin her metrikte toplam kayıtların yaklaşık %1'i düzeyinde anomali işaretlediğini göstermektedir. Bu bulgu, modelin bütün veri setini olağan dışı kabul etmediğini; yalnızca dağılımdan ayrılan sınırlı sayıda noktayı erken uyarı adayı olarak seçtiğini göstermesi bakımından önemlidir. Tablodaki anomali sayıları kesin arıza sayısı olarak değil, dashboard ve olay günlüğü üzerinden uzman incelemesine sunulan karar destek sinyalleri olarak değerlendirilmelidir.



5.2. Karşılaştırmalı Algoritma Deneyleri

Isolation Forest modelinin tercih nedeni, alternatif algoritmalarla yapılan deneyler üzerinden değerlendirilmiştir. Karşılaştırmada anomali sayısı, oran, çalışma süresi ve Isolation Forest ile Jaccard benzerliği birlikte kullanılmıştır.

Tablo 5.3. CPU Kullanımı metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	169	%0,94	219,91	1,0000
One-Class SVM	994	%5,51	339,55	0,0356
Local Outlier Factor	155	%0,86	69,57	0,0000
Z-Score	842	%4,66	0,14	0,0000

CPU Kullanımı üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.4. Disk Yazma metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	46	%0,97	98,03	1,0000
One-Class SVM	4.312	%91,16	18,73	0,0060
Local Outlier Factor	40	%0,85	199,47	0,0238
Z-Score	94	%1,99	0,09	0,4894

Disk Yazma üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.5. Ağ Girişi metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	41	%1,02	109,22	1,0000
One-Class SVM	41	%1,02	10,22	0,2239
Local Outlier Factor	36	%0,89	14,26	0,2419
Z-Score	4	%0,10	0,08	0,0976

Ağ Girişi üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.6. İstek Sayısı metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	41	%1,02	121,88	1,0000
One-Class SVM	194	%4,81	24,84	0,0633
Local Outlier Factor	0	%0,00	14,13	0,0000
Z-Score	98	%2,43	0,08	0,4184

İstek Sayısı üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.7. İstek Gecikmesi metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	39	%0,97	125,07	1,0000
One-Class SVM	602	%14,93	76,20	0,0355
Local Outlier Factor	40	%0,99	14,55	0,0822
Z-Score	39	%0,97	0,09	0,6250

İstek Gecikmesi üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.8. RAM Kullanımı metriği karşılaştırmalı deney sonuçları

Algoritma	Anomali	Oran	Süre (ms)	IF ile Jaccard
Isolation Forest	19	%0,95	96,58	1,0000
One-Class SVM	92	%4,60	9,93	0,0990
Local Outlier Factor	16	%0,80	7,41	0,0938
Z-Score	9	%0,45	0,08	0,4737

RAM Kullanımı üzerinde elde edilen sonuçlar, algoritmaların yalnızca alarm sayısı bakımından değil, hangi noktaları anomali olarak seçtikleri bakımından da farklılaştığını göstermektedir. Bu nedenle model seçimi yapılırken çalışma süresi, alarm yoğunluğu, karar örtüşmesi ve yorumlanabilirlik birlikte değerlendirilmiştir.



Tablo 5.9. Isolation Forest güvenilirlik ve stabilite analizi

Metrik	Kayıt	Ortalama anomali	%95 GA	Ortalama Jaccard
CPU Kullanımı	18050	175,20 $\pm$ 6,72	169,31-181,09	0,8027
Disk Yazma	4730	46,00 $\pm$ 1,22	44,93-47,07	0,9496
Ağ Girişi	4032	41,00 $\pm$ 0,00	41,00-41,00	0,8737
İstek Sayısı	4032	40,80 $\pm$ 0,45	40,41-41,19	0,9760
İstek Gecikmesi	4032	40,20 $\pm$ 0,84	39,47-40,93	0,8211
RAM Kullanımı	2000	19,60 $\pm$ 0,55	19,12-20,08	0,9143

Isolation Forest modeli farklı rassal tohumlarla tekrar çalıştırılmış ve anomali sayısı, %95 güven aralığı ve karar kümeleri arasındaki ortalama Jaccard benzerliği hesaplanmıştır. Etiketli olay verisi bulunmadığı için bu analiz klasik anlamda kesin doğruluk testi değil, model kararlarının istatistiksel güvenilirliğini ve tekrarlanabilirliğini gösteren destekleyici analiz olarak yorumlanmıştır.



Tablo 5.10. McNemar anlamlılık testi p değerleri

Metrik	OC-SVM	LOF	Z-Score	MLP AE	Temporal AE
CPU Kullanımı	<0,001	0,470	<0,001	0,557	0,551
Disk Yazma	<0,001	0,581	<0,001	0,500	0,914
Ağ Girişi	1,000	0,560	<0,001	1,000	1,000
İstek Sayısı	<0,001	<0,001	<0,001	1,000	1,000
İstek Gecikmesi	<0,001	1,000	1,000	0,894	0,888
RAM Kullanımı	<0,001	0,711	0,002	1,000	1,000

Model kararlarının istatistiksel anlamlılığı, her alternatif yöntemin ikili anomali kararları Isolation Forest kararlarıyla eşleştirilerek exact McNemar testiyle incelenmiştir. Bu p değerleri, etiketli arıza sınıfı bulunmadığı için denetimli doğruluk üstünlüğü değil, algoritmaların aynı veri noktaları üzerinde anlamlı derecede farklı karar verip vermediğini gösteren eşleştirilmiş karar testi olarak yorumlanmıştır.



Tablo 5.11. Derin öğrenme tabanlı autoencoder karşılaştırmalı sonuçları

Metrik	Isolation Forest	MLP AE	Temporal MLP AE	MLP Jaccard	Temporal Jaccard
CPU Kullanımı	169 / %0,94	181 / %1,00	181 / %1,00	0,0000	0,0145
Disk Yazma	46 / %0,97	48 / %1,01	48 / %1,01	0,9583	0,0444
Ağ Girişi	41 / %1,02	41 / %1,02	41 / %1,02	0,2239	0,0789
İstek Sayısı	41 / %1,02	41 / %1,02	41 / %1,02	1,0000	0,1233
İstek Gecikmesi	39 / %0,97	41 / %1,02	41 / %1,02	0,1765	0,2308
RAM Kullanımı	19 / %0,95	20 / %1,00	20 / %1,00	0,4444	0,0263

Derin öğrenme tabanlı güncel yaklaşımlarla karşılaştırma gereksinimini karşılamak için iki autoencoder varyantı uygulanmıştır. Birinci yaklaşım tekil metrik değeri üzerinden rekonstrüksiyon hatası kullanan MLP Autoencoder, ikinci yaklaşım ise 12 noktalı zaman pencereleriyle çalışan Temporal MLP Autoencoder modelidir. Böylece derin öğrenme tabanlı yöntemler yalnızca gelecek çalışma önerisi olarak bırakılmamış, mevcut veri setleri üzerinde karşılaştırmalı performans tablosuna dahil edilmiştir.




Tablo 5.12. Sentetik concept drift stres testi sonuçları

Metrik	IF orijinal -> drift	Z-Score orijinal -> drift	MLP orijinal -> drift	Temporal AE orijinal -> drift
CPU Kullanımı	42 -> 39	390 -> 904	0 -> 225	1075 -> 1681
Disk Yazma	11 -> 12	13 -> 16	11 -> 12	35 -> 75
Ağ Girişi	1 -> 751	0 -> 0	0 -> 764	0 -> 615
İstek Sayısı	10 -> 31	27 -> 88	10 -> 31	28 -> 55
İstek Gecikmesi	17 -> 47	29 -> 80	25 -> 76	54 -> 60
RAM Kullanımı	3 -> 50	0 -> 50	0 -> 53	2 -> 1


Concept drift etkisini deneysel olarak incelemek için veri serilerinin son penceresine kontrollü seviye kayması eklenmiş ve algoritmaların son pencere alarm sayılarındaki değişim raporlanmıştır. Bu stres testi, model performansının değişen sistem davranışından etkilenebildiğini ve üretim ortamında periyodik yeniden eğitim veya kayan pencere güncellemesi gerekeceğini göstermektedir.





Şekil 5.1. Algoritmalar arası karşılaştırmalı deney ekranı

Karşılaştırma ekranı Isolation Forest, One-Class SVM, LOF ve Z-Score yöntemlerini anomali sayısı, oran, çalışma süresi ve Jaccard benzerliği ile birlikte sunar. Bu ekran model tercihinin deneysel dayanağını görünür hale getirir.



Şekil 5.2. Canlı telemetri ve erken uyarı ekranı

Canlı telemetri ekranı simülasyonla gelen yeni veri noktalarını grafik ve alarm listesi üzerinden gösterir. Kullanıcı, erken uyarının hangi değerle tetiklendiğini ve sistemin nasıl tepki verdiğini takip eder.

5.3. Metrik Bazlı Bulguların Yorumlanması

CPU Kullanımı Bulgularının Yorumu

CPU kullanım verisi, 18.050 kayıt ile çalışmadaki en geniş zaman penceresini temsil etmektedir. Isolation Forest bu metrikte 169 anomali üretmiş ve oran yaklaşık %0,94 düzeyinde kalmıştır. Bu sonuç, modelin yüksek kayıt sayısına rağmen alarm yoğunluğunu kontrol altında tuttuğunu göstermektedir.

OC-SVM aynı veri üzerinde daha yüksek alarm sayısı üretmiştir. Bu durum, sınır temelli yaklaşımın CPU kullanımındaki doğal dalgalanmaları olağan dışı olarak yorumlama eğilimini göstermektedir. LOF ve Z-Score sonuçlarının Isolation Forest ile düşük Jaccard benzerliği göstermesi, yöntemlerin aynı anomali noktalarını seçmediğini ortaya koymaktadır.

Operasyonel açıdan CPU metriği erken uyarı sistemleri için kritik öneme sahiptir; çünkü CPU tüketimindeki artışlar uygulama gecikmesi, kuyruk birikmesi veya kaynak yoğunluğu gibi durumların ön belirtisi olabilir. Bu nedenle CPU sonucunun dashboard üzerinde grafik ve tabloyla birlikte sunulması, kullanıcının yalnızca alarm sayısını değil olayın zaman içindeki bağlamını da değerlendirmesini sağlar.



Disk Yazma Bulgularının Yorumu

Disk yazma metriğinde Isolation Forest 46 anomali üretmiş ve oran yaklaşık %0,97 olmuştur. Buna karşılık OC-SVM'nin aynı veri üzerinde çok yüksek sayıda alarm üretmesi, bu yöntemin disk metriği dağılımına karşı aşırı duyarlı davrandığını göstermektedir.

Disk yazma davranışı, toplu veri aktarımı, yedekleme, log yoğunluğu veya beklenmeyen depolama işlemleri nedeniyle dönemsel sıçramalar gösterebilir. Bu nedenle yalnızca sabit eşik veya sınır temelli yöntem kullanıldığında yanlış alarm üretimi artabilir. Isolation Forest'ın daha dengeli alarm üretmesi, bu metrik için tercih gerekçesini güçlendirmektedir.

Bu bulgu, false positive tartışması açısından da önemlidir. Disk yoğunluğu bazı zamanlarda planlı bakım veya normal iş yükü nedeniyle artabilir. Sistem çıktısının uzman değerlendirmesine sunulan karar destek sinyali olarak tasarlanması, bu tür bağlamsal farkların kullanıcı tarafından yorumlanmasına olanak tanır.



Ağ Girişi Bulgularının Yorumu

Ağ girişi metriğinde Isolation Forest 41 anomali üretmiş ve oran yaklaşık %1,02 düzeyinde kalmıştır. OC-SVM aynı sayıda alarm üretmiş olsa da Jaccard benzerliği düşük kalmıştır; bu durum iki algoritmanın aynı alarm sayısına rağmen farklı noktaları işaretlediğini göstermektedir.

Ağ trafiği bulut sistemlerinde dış kullanıcı talebi, servisler arası iletişim, veri senkronizasyonu veya saldırı benzeri olağan dışı davranışlardan etkilenebilir. Bu nedenle ağ metriğinde yalnızca alarm sayısına bakmak yanıltıcıdır. Hangi zaman noktalarının seçildiği ve bu noktaların trafik bağlamı birlikte incelenmelidir.

Dashboard üzerinde ağ trafiğinin görselleştirilmesi, kullanıcıya ani trafik artışlarını veya beklenmeyen düşüşleri zaman ekseninde değerlendirme olanağı sunar. Böylece model çıktısı, izleme sürecinde operasyonel bir inceleme başlangıç noktası haline gelir.



İstek Sayısı Bulgularının Yorumu

İstek sayısı metriği, uygulama kullanım yoğunluğunu doğrudan yansıtan göstergelerden biridir. Isolation Forest bu metrikte 41 anomali üretmiştir. LOF'un hiç anomali üretmemesi, yerel yoğunluk yaklaşımının bu veri dağılımında sapmaları yeterince ayıramadığını düşündürmektedir.

Z-Score yöntemi bu metrikte daha fazla alarm üretmiş, ancak karar benzerliği sınırlı kalmıştır. Bu durum, istatistiksel uç değerlerin her zaman operasyonel açıdan anlamlı sapmalarla örtüşmeyebileceğini göstermektedir. İstek sayısı gibi trafik metriklerinde trend, dönemsel yoğunluk ve kampanya etkisi dikkate alınmalıdır.

Erken uyarı açısından istek sayısındaki ani artışlar kapasite planlaması ve yük dengeleme kararları için önemlidir. Bu nedenle sistemin istek sayısı metriğini ayrı bir seri olarak işlemesi, kaynak tüketimi ve uygulama talebi arasındaki ilişkinin daha iyi yorumlanmasını sağlar.



İstek Gecikmesi Bulgularının Yorumu

İstek gecikmesi metriği kullanıcı deneyimiyle doğrudan ilişkilidir. Isolation Forest bu metrikte 39 anomali üretmiş ve oran yaklaşık %0,97 olmuştur. Z-Score da benzer sayıda alarm üretmiş, ancak bu sonuç iki yöntemin tamamen aynı noktaları seçtiği anlamına gelmemektedir.

Gecikme metriğinde küçük sapmalar bile hizmet kalitesi açısından önemli olabilir. CPU veya ağ metriğinde kabul edilebilir görünen bir değişim, gecikme metriğinde kullanıcı tarafında hissedilebilir performans düşüşüne dönüşebilir. Bu nedenle gecikme verisi erken uyarı sisteminin öncelikli izleme alanlarından biri olarak değerlendirilmiştir.

OC-SVM'nin daha yüksek alarm sayısı üretmesi, gecikme dağılımındaki değişkenliğe karşı duyarlı olduğunu göstermektedir. Bu bulgu, üretim ortamında alarm eşiği ve model parametresi ayarlarının metrik türüne göre yapılması gerektiğini desteklemektedir.



RAM Kullanımı Bulgularının Yorumu

RAM kullanım metriğinde Isolation Forest 19 anomali üretmiş ve oran yaklaşık %0,95 düzeyinde kalmıştır. Bu sonuç, kısa fakat sık örneklenen RAM telemetri verisinde modelin kontrollü alarm yoğunluğu sağladığını göstermektedir.

RAM verisi, sistem belleğinin kullanımı, kullanılabilir alanı ve boş alanı gibi ilişkili değişkenleri içerdiği için diğer metriklerden farklıdır. Bu yapı, bellek baskısı gibi durumların birden fazla gösterge üzerinden değerlendirilmesine imkan tanır.

RAM kullanımındaki anomali yalnızca yüksek tüketim anlamına gelmez; beklenmeyen düşüşler, ani boşalma veya ölçüm dengesizliği de sistem davranışı açısından anlamlı olabilir. Bu nedenle RAM metrikleri canlı telemetri ekranında erken uyarı senaryosu için özellikle uygun bir örnek alan sunmaktadır.



RAM Kullanılabilir ve RAM Boş Bulgularının Yorumu

RAM kullanılabilir ve RAM boş metrikleri, bellek kullanımının ters yönlü göstergeleri olarak değerlendirilmiştir. Bu iki metrikte ortaya çıkan sapmalar, sistemde bellek baskısının veya beklenmeyen kaynak boşalmasının erken göstergesi olabilir.

Isolation Forest'ın bu metriklerde yaklaşık %1 civarında anomali üretmesi, modelin bellek telemetrisinde de yönetilebilir alarm hacmi sağlayabildiğini göstermektedir. Ancak bellek metrikleri birbiriyle ilişkili olduğundan üretim ortamında çok değişkenli modelleme yaklaşımı daha güçlü sonuçlar verebilir.

Bu bulgu, çalışmanın gelecek önerileriyle de ilişkilidir. İlerleyen sürümlerde RAM, CPU ve istek gecikmesi birlikte değerlendirilerek sistem kaynakları ile kullanıcı deneyimi arasındaki ilişki daha kapsamlı biçimde modellenebilir.



Genel Bulguların Yorumu

Sekiz metrik birlikte değerlendirildiğinde, Isolation Forest algoritmasının düşük ve yönetilebilir alarm oranı ürettiği görülmektedir. Bu durum, erken uyarı sistemlerinde önemli olan alarm yorgunluğunu azaltma hedefiyle uyumludur.

Karşılaştırmalı deneyler, algoritmaların aynı veri seti üzerinde farklı davranış gösterebildiğini ortaya koymuştur. Bu nedenle çalışmada model başarımı yalnızca tek bir sayısal ölçütle açıklanmamış; alarm oranı, çalışma süresi, karar benzerliği, kullanıcıya sunulabilirlik ve sistem entegrasyonu birlikte ele alınmıştır.

Bu genel bulgu, projenin ana iddiasını desteklemektedir: bulut sistemlerinde anomali tespiti yalnızca algoritma seçimiyle tamamlanan bir problem değildir. Veri hazırlama, model karşılaştırması, API tasarımı, kullanıcı arayüzü ve erken uyarı mantığı birlikte tasarlandığında daha anlamlı bir karar destek sistemi ortaya çıkmaktadır.



BÖLÜM VI TARTIŞMA

6.1. Model Tercihinin Değerlendirilmesi

Deneyisel bulgular, Isolation Forest algoritmasının bu çalışma için dengeli bir tercih olduğunu göstermektedir. Z-Score çalışma süresi bakımından en hızlı yöntemdir; ancak yalnızca global uç değerleri yakaladığı için bağlamsal anomalilerde sınırlı kalır. OC-SVM bazı metriklerde yüksek alarm oranı üretmiş, LOF ise yerel yoğunluk yaklaşımına rağmen her metrikte tutarlı karar örtüşmesi sağlayamamıştır.

Ek revizyonda iki derin öğrenme tabanlı autoencoder yaklaşımı uygulanmıştır: tekil değer rekonstrüksiyonuna dayalı MLP Autoencoder ve 12 noktalı zaman pencereleriyle çalışan Temporal MLP Autoencoder. Bu deneyler, derin öğrenme tabanlı yaklaşımların bazı metriklerde Isolation Forest ile yüksek karar örtüşmesi gösterebildiğini, bazı metriklerde ise farklı noktaları anomali olarak seçtiğini ortaya koymuştur. Ayrıca McNemar testiyle algoritmaların ikili karar farklılıkları p değeri düzeyinde raporlanmıştır.

Isolation Forest, etiketli veri gerektirmemesi, doğrusal düzeye yakın çalışma maliyeti ve farklı metrikler üzerinde yönetilebilir alarm yoğunluğu üretmesi nedeniyle bulut izleme senaryosuna uygun görülmüştür. Bununla birlikte bu sonuç, algoritmanın her ortamda tek başına yeterli olduğu anlamına gelmez; üretim ortamında model parametreleri ve veri penceresi düzenli olarak yeniden değerlendirilmelidir.

6.2. False Positive, Concept Drift ve Ölçeklenebilirlik

False positive üretimi, gözetimsiz anomali tespit sistemlerinin temel sınırlılıklarından biridir. Planlı bakım, kampanya dönemi, veri aktarımı veya olağan trafik artışı sistem tarafından anomali olarak işaretlenebilir. Bu nedenle alarm çıktısı otomatik kesin hüküm değil, uzman değerlendirmesine sunulan karar destek sinyali olarak ele alınmalıdır.

Concept drift, sistemin normal davranışının zamanla değişmesi durumudur. Yeni sunucu eklenmesi, uygulama sürümünün değişmesi, kullanıcı kitlesinin büyümesi veya kaynak limitlerinin yeniden ayarlanması modelin öğrendiği normal çizgiyi geçersiz hale getirebilir. Bu riski azaltmak için periyodik yeniden eğitim ve kayan pencere tabanlı güncelleme yaklaşımı gereklidir.

Bu revizyonda concept drift yalnızca kuramsal bir sınırlılık olarak bırakılmamış, sentetik seviye kayması eklenen veri pencereleri üzerinde deneysel olarak incelenmiştir. Drift uygulanan son pencerede özellikle Z-Score, Isolation Forest, MLP Autoencoder ve Temporal MLP Autoencoder çıktılarının alarm yoğunluğu değişmiş; bu sonuç model davranışının sistem koşulları değiştiğinde yeniden doğrulanması gerektiğini göstermiştir.

Ölçeklenebilirlik bakımından prototip yapı, araştırma ve gösterim amacı için yeterlidir. Üretim ortamında ise saniyede binlerce veri noktası oluşabileceğinden zaman serisi veritabanı, mesaj kuyruğu, stream processing katmanı ve yatay ölçeklenebilir backend mimarisi gerekebilir.

6.3. Akademik Yorum

Çalışmanın bulguları, anomali tespitinde tek bir algoritma sonucunun mutlak doğru kabul edilemeyeceğini göstermektedir. Farklı yöntemler aynı sayıda alarm üretse bile aynı veri noktalarını işaretlemeyebilir. Bu nedenle model başarımı, yalnızca alarm oranı üzerinden değil, karar örtüşmesi, çalışma süresi ve operasyonel yorumlanabilirlik üzerinden değerlendirilmelidir.

Bu açıdan çalışma, teknik dokümantasyondan daha geniş bir akademik tartışma alanına taşınmaktadır. Model seçimi, veri seti özellikleri, canlı sistem gereksinimleri ve sınırlılıklar birlikte değerlendirildiğinde geliştirilen prototipin hem araştırma hem de uygulama boyutu ortaya çıkmaktadır.

6.4. Geçerlilik ve Güvenilirlik Değerlendirmesi

Çalışmanın iç geçerliliği, tüm algoritmaların aynı veri kümeleri üzerinde çalıştırılmasıyla güçlendirilmiştir. Bu sayede yöntemler arasındaki farklar veri kaynağı değişiminden değil, algoritmik karar mekanizmasından kaynaklanmaktadır. Ayrıca aynı ön işleme adımlarının kullanılması, karşılaştırmalı deneylerin tutarlılığını artırmıştır.

Dış geçerlilik açısından çalışma, seçilen veri kümelerinin bulut metriklerini temsil etmesi nedeniyle gerçek operasyon senaryolarına yakındır. Ancak üretim ortamında farklı uygulama

tipleri, farklı trafik örüntüleri ve farklı kaynak limitleri bulunabileceğinden, model parametrelerinin doğrudan her ortama aktarılması uygun değildir.

Farklı veri setleri üzerinde yapılan deneyler, modelin tek bir metrik davranışına göre değerlendirilmediğini göstermektedir. CPU, disk, ağ, istek sayısı, istek gecikmesi ve RAM verilerinde elde edilen sonuçlar birlikte ele alınarak çalışmanın genellenebilirlik iddiası daha kontrollü biçimde desteklenmiştir.

Güvenilirlik bakımından pipeline çıktılarının yeniden üretilebilir olması önemlidir. Aynı CSV dosyaları ve aynı analiz adımları kullanıldığında model çıktıları tekrar oluşturulabilir. Bu durum, çalışmanın akademik raporlama boyutunda doğrulanabilir bir temel oluşturur.

Ek güvenilirlik analizinde Isolation Forest farklı random seed değerleriyle tekrar çalıştırılmış, anomali sayısı için ortalama, standart sapma, %95 güven aralığı ve karar kümeleri arasındaki Jaccard benzerliği hesaplanmıştır. Bu ek analiz, etiketli doğruluk metriği bulunmayan bir çalışmada model kararlarının ne ölçüde kararlı olduğunu göstermesi bakımından önemlidir.

Bununla birlikte gözetimsiz anomali tespitinde kesin doğruluk iddiası dikkatli kurulmalıdır. Etiketli olay kayıtları bulunmadığında model çıktıları aday anomali olarak yorumlanmalı; nihai değerlendirme sistem uzmanının bağlamsal bilgisiyle desteklenmelidir.

6.5. Sektörel Uygulanabilirlik Tartışması

Sektörel uygulamalarda erken uyarı sistemlerinin başarısı, teknik doğruluk, kullanıcı iş akışına uyum, alarm yorumlanabilirliği ve raporlanabilirlik boyutlarının birlikte ele alınmasıyla güçlenir. Bu nedenle projede dashboard, detay ekranı, alarm listesi ve dışa aktarma gibi pratik kullanım bileşenlerine yer verilmiştir.

Prototipin operasyonel kullanılabilirliğini değerlendirmek amacıyla sistem, Doğru Bulut firmasında görev yapan iki sektör profesyonelinin uzman görüşüne sunulmuştur. Değerlendirme, biri bilgisayar mühendisliği temelli bulut sistemleri ve altyapı operasyonları, diğeri yönetim bilişim sistemleri temelli sistem destek ve operasyonel izleme süreçleri konusunda deneyimli iki uzman tarafından; dashboard ekranı, metrik detay görünümü, canlı telemetri akışı, alarm listesi, dışa aktarma işlevleri ve erken uyarı mantığının karar desteğine katkısı üzerinden yapılmıştır.

Uzman değerlendirmeleri sonucunda arayüzün anlaşılabilirliği, alarm çıktılarının yorumlanabilirliği, canlı telemetri akışının operasyonel izleme süreçlerine uygunluğu ve dışa aktarma özelliklerinin raporlama açısından faydası olumlu bulunmuştur. Bu bulgu, prototipin teknik model çıktısını yazılım, sistem destek ve cloud operasyon ekiplerinin inceleme süreçlerinde kullanabileceği anlaşılır bir karar destek aracına dönüştürdüğünü göstermektedir. Değerlendirici profilleri ve görüş özetleri EK-G'de verilmiştir.

Uzman görüşlerinde öne çıkan ortak nokta, alarm çıktılarının operasyonel inceleme sürecini hızlandırabilecek ve dikkat edilmesi gereken olayları önceliklendirebilecek biçimde sunulmasıdır. Bu yaklaşım, gözetimsiz anomali tespiti ürettiği aday olayların sistem uzmanları tarafından bağlam içinde değerlendirilmesine uygun bir çalışma modeli oluşturmaktadır.

Murat Poyraz tarafından yapılan değerlendirme, cloud sistemleri, hosted exchange, disaster recovery ve sanallaştırma gibi altyapı operasyonları açısından prototipin metrik çeşitliliğini ve alarm mantığını olumlu biçimde desteklemiştir. Bu görüş, sistemin bulut izleme süreçlerinde kullanılabilecek teknik karar destek niteliğini güçlendirmektedir.

Melih Kutlay tarafından yapılan değerlendirme ise sistem destek süreçleri, arayüz kullanılabilirliği, alarm listesi, canlı izleme ekranı ve raporlama/dışa aktarma işlevleri açısından prototipin anlaşılır ve uygulanabilir bir yapı sunduğunu göstermektedir. Bu değerlendirme, sistemin operasyon ekipleri tarafından okunabilir ve izlenebilir bir araç olarak konumlanmasına katkı sağlamaktadır.

Bu değerlendirmeler birlikte ele alındığında geliştirilen erken uyarı prototipi, model çıktısını operasyonel inceleme akışına taşıyan tamamlanmış bir karar destek sistemi olarak değerlendirilebilir. Çalışma; veri işleme, model karşılaştırması, canlı telemetri, kullanıcı arayüzü ve uzman değerlendirmesini aynı proje bütünlüğü içinde bir araya getirmektedir.



BÖLÜM VII SONUÇ VE ÖNERİLER

7.1. Sonuç

Bu dönem projesi kapsamında bulut sistemlerinde yapay zeka destekli anomali tespiti ve erken uyarı üretebilen uçtan uca bir prototip geliştirilmiştir. Sistem, ham metrik verilerini temizleyerek Isolation Forest modeliyle analiz etmekte, sonuçları FastAPI üzerinden sunmakta ve Next.js tabanlı dashboard ile kullanıcıya ulaştırmaktadır.

Çalışma kapsamında veri seti yapısı ayrıntılı biçimde tanımlanmış, model tercihi alternatif algoritmalarla karşılaştırılmış, canlı telemetri akışı geliştirilmiş ve sistem sınırlılıkları tartışılmıştır. Böylece proje, yalnızca model çalıştıran bir deney olmaktan çıkarak bütünleşik bir gözlemlenebilirlik ve erken uyarı prototipine dönüşmüştür.

7.2. Literatüre ve Sektörel Uygulamalara Katkı

Literatür açısından çalışma, gözetimsiz anomali tespiti yöntemlerinin bulut performans metrikleri üzerinde karşılaştırmalı biçimde uygulanmasına örnek sunmaktadır. Isolation Forest, OC-SVM, LOF ve Z-Score yöntemlerinin aynı veri yapıları üzerinde değerlendirilmesi, model tercihinin gerekçelendirilmesine katkı sağlar.

Sektörel açıdan çalışma, küçük ve orta ölçekli yazılım ekiplerinin performans izleme süreçlerinde kullanabileceği geliştirilebilir bir prototip ortaya koymaktadır. Dashboard, rol tabanlı güvenlik, dışa aktarma ve canlı uyarı bileşenlerinin birlikte sunulması, sistemin gerçek operasyon senaryolarına uyarlanabilirliğini güçlendirmektedir.

7.3. Öneriler

Gelecek çalışmalarda gerçek üretim ortamlarından etiketli olay kayıtları toplanarak precision, recall ve F1-score gibi ölçütler hesaplanabilir. Ayrıca Prometheus, Kafka veya zaman serisi veritabanı entegrasyonlarıyla canlı veri akışı üretim ortamına yaklaştırılabilir.

False positive oranını azaltmak için alarm doğrulama arayüzü ve kullanıcı geri bildirimi eklenebilir. Concept drift'e karşı modelin belirli aralıklarla yeniden eğitilmesi ve çok değişkenli metrik ilişkilerinin birlikte değerlendirilmesi de çalışmanın devamı için önemli geliştirme alanlarıdır.

Derin öğrenme karşılaştırması bu revizyonda MLP Autoencoder ve Temporal MLP Autoencoder olmak üzere iki autoencoder varyantıyla sınanmıştır. Gelecek çalışmalarda LSTM Autoencoder, Temporal Convolutional Network ve Transformer tabanlı zaman serisi modelleri daha büyük ve etiketli üretim verileriyle ayrıca genişletilebilir.

Uzman değerlendirmesi sonucunda olumlu bulunan erken uyarı ekranı, ilerleyen sürümlerde daha geniş operasyon ekipleriyle görev tamamlama süresi, alarm yorumlama doğruluğu, müdahale önceliklendirme başarısı ve kullanıcı memnuniyeti gibi ölçülebilir göstergeler üzerinden ayrıca değerlendirilebilir. Bu öneri, mevcut prototipin operasyonel karar destek niteliğini daha farklı kurum ve ekip yapılarında doğrulamaya yöneliktir.

7.4. Özgün Katkının Değerlendirilmesi

Çalışmanın özgün katkısı, bulut performans metrikleri için gözetimsiz anomali tespiti modelini uçtan uca çalışan bir web tabanlı erken uyarı prototipiyle birleştirmesidir. Bu kapsamda veri işleme, modelleme, algoritma karşılaştırması, API tasarımı, kimlik doğrulama ve kullanıcı arayüzü aynı proje bütünlüğü içinde ele alınmıştır.

Literatürde anomali tespiti çoğu zaman model performansı üzerinden tartışılırken, bu çalışmada model çıktısının kullanıcıya nasıl sunulduğu ve operasyonel karara nasıl dönüştüğü de önemsenmiştir. Bu durum çalışmanın uygulamalı yapay zeka ve bulut gözlemlenebilirliği kesişiminde konumlanmasını sağlar.

Karşılaştırmalı deneylerin bulgular bölümünde açık biçimde verilmesi, Isolation Forest tercihinin akademik dayanağını güçlendirmiştir. Modelin seçimi yalnızca teorik avantajlara değil, proje verisi üzerinde üretilen sonuçlara dayandırılmıştır.

Sonuç olarak çalışma, yüksek lisans dönem projesi düzeyinde hem teknik uygulama hem de akademik değerlendirme gerekliliklerini bir araya getiren, geliştirilmeye açık ve sektörel kullanıma uyarlanabilir bir örnek ortaya koymaktadır.

KAYNAKÇA

- Ahmad, S., Lavin, A., Purdy, S., & Agha, Z. (2017). Unsupervised real-time anomaly detection for streaming data. *Neurocomputing*, 262, 134-147.
<https://doi.org/10.1016/j.neucom.2017.04.070>
- Breunig, M. M., Kriegel, H. P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 93-104. <https://doi.org/10.1145/342009.335388>
- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), Article 15. <https://doi.org/10.1145/1541880.1541882>
- FastAPI. (2026). FastAPI documentation. Retrieved May 23, 2026, from <https://fastapi.tiangolo.com/>
- Gama, J., Zliobaite, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), Article 44.
<https://doi.org/10.1145/2523813>
- Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *Science*, 313(5786), 504-507. <https://doi.org/10.1126/science.1127647>
- Lavin, A., & Ahmad, S. (2015). Evaluating real-time anomaly detection algorithms: The Numenta Anomaly Benchmark. 2015 IEEE 14th International Conference on Machine Learning and Applications, 38-44.
- Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation Forest. 2008 Eighth IEEE International Conference on Data Mining, 413-422. <https://doi.org/10.1109/ICDM.2008.17>
- Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). Long short term memory networks for anomaly detection in time series. *Proceedings of the European Symposium on Artificial Neural Networks*, 89-94.
- Mell, P., & Grance, T. (2011). The NIST definition of cloud computing (Special Publication 800-145). National Institute of Standards and Technology.
<https://doi.org/10.6028/NIST.SP.800-145>
- Numenta. (2015). Numenta Anomaly Benchmark (NAB) [Data set]. GitHub.
<https://github.com/numenta/NAB>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Pang, G., Shen, C., Cao, L., & van den Hengel, A. (2021). Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2), Article 38.
<https://doi.org/10.1145/3439950>
- Ruff, L., Vandermeulen, R., Goernitz, N., Deecke, L., Siddiqui, S. A., Binder, A., Müller, E., & Kloft, M. (2018). Deep one-class classification. *Proceedings of the 35th International Conference on Machine Learning*, 80, 4393-4402.
- Sakurada, M., & Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. *Proceedings of the Workshop on Machine Learning for Sensory Data Analysis*, 4-11.

- Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. J., & Williamson, R. C. (2001). Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7), 1443-1471. <https://doi.org/10.1162/089976601750264965>
- Supabase. (2026). Supabase documentation. Retrieved May 23, 2026, from <https://supabase.com/docs>
- Vercel. (2026). Next.js documentation. Retrieved May 23, 2026, from <https://nextjs.org/docs>
- Uzkal, Ö. F. (2026). Proje kapsamında kullanılan CSV veri dosyaları [Veri seti]. `cpu_utilization_asg_misconfiguration.csv`, `ec2_disk_write_bytes_1ef3de.csv`, `ec2_network_in_257a54.csv`, `ec2_request_latency_system_failure.csv`, `elb_request_count_8c0756.csv` ve `ram_telemetry.csv`.



EKLER

EK-A. Kullanılan CSV Veri Dosyaları

cpu_utilization_asg_misconfiguration.csv: CPU kullanım oranı zaman serisini içerir ve sistem yükündeki beklenmeyen artışları değerlendirmek için kullanılmıştır.

ec2_disk_write_bytes_1ef3de.csv: EC2 disk yazma aktivitesini temsil eder ve depolama davranışındaki olağan dışı değişimleri incelemek için kullanılmıştır.

ec2_network_in_257a54.csv: Ağ giriş trafiğini temsil eder. Trafik yoğunluğu ve beklenmeyen ağ davranışlarının izlenmesinde kullanılmıştır.

ec2_request_latency_system_failure.csv: İstek gecikmesi metriğini içerir ve hizmet yanıt süresindeki sapmaları analiz etmek için kullanılmıştır.

elb_request_count_8c0756.csv: Yük dengeleyici istek sayısı metriğini içerir ve trafik hacmindeki olağan dışı örüntüleri değerlendirmek için kullanılmıştır.

ram_telemetry.csv: RAM kullanımı, kullanılabilir bellek ve boş bellek metriklerinin türetilmesinde kullanılmıştır.



EK-B. Test ve Doğrulama Çıktıları

Backend testleri pytest ile çalıştırılmış ve 87 test başarıyla tamamlanmıştır.

Frontend kod kalitesi ESLint ile kontrol edilmiş ve hata alınmamıştır.

Next.js production build süreci başarıyla tamamlanmıştır.

Tez ekran görüntüleri production frontend üzerinden alınmış, karşılaştırma ve canlı telemetri ekranlarında gerçek API yanıtları kullanılmıştır.



EK-C. Canlı Erken Uyarı Senaryosu

Kullanıcı canlı akış ekranından CPU veya RAM metriğini seçer.

Simülasyon başlatıldığında frontend belirli aralıklarla backend'e yeni telemetri noktası gönderir.

Backend kayan pencere içindeki son değerleri kullanarak sapma hesabı yapar.

Eşik aşımı gerçekleştiğinde aktif uyarı listesine yeni alarm eklenir.

Kullanıcı grafik, log akışı ve alarm kartları üzerinden olayın ne zaman ve hangi değerle tetiklendiğini inceler.



EK-D. Veri Sözlüğü ve Alan Açıklamaları

timestamp: Her ölçümün zaman eksenindeki konumunu gösterir. Zaman serisi analizinde kayıtların sıralanması ve görselleştirilmesi bu alan üzerinden yapılır.

value: İlgili metriğin sayısal ölçüm değeridir. CPU oranı, disk yazma miktarı, ağ girişi, istek sayısı veya gecikme süresi gibi farklı anlamlara gelebilir.

metric: Dashboard içinde hangi veri serisinin gösterileceğini belirleyen tanımlayıcıdır. Bu alan kullanıcı arayüzünde metrik seçimi ve API yanıtlarının ayrıştırılması için kullanılır.

anomaly: Model çıktısında gözlemin olağan dışı olarak işaretlenip işaretlenmediğini gösterir. Bu değer alarm listesi ve grafik üzerindeki vurgu noktaları için temel alınır.

score: Modelin gözleme ilişkin anomali derecesini temsil eder. Daha güçlü sapmalar kullanıcıya daha yüksek risk bağlamında sunulabilir.

available_memory, used_memory ve free_memory: RAM telemetri dosyasında bellek durumunu açıklayan alanlardır. Bu alanlardan RAM kullanım, kullanılabilir ve boş bellek metrikleri türetilmiştir.



EK-E. Çalıştırma ve Doğrulama Adımları

Backend tarafında analiz pipeline'ı CSV dosyalarını okuyarak temizlenmiş zaman serileri üretir. Model çıktıları backend API tarafından frontend'e sunulur.

Frontend tarafında dashboard, metrik detay, karşılaştırmalı deney ve canlı telemetri ekranları kullanıcı tarafından gezilebilir biçimde hazırlanmıştır.

Backend testleri, model ve API davranışının bozulmadığını doğrulamak amacıyla çalıştırılmıştır. Test çıktısı 87 testin başarılı olduğunu göstermiştir.

Frontend üretim derlemesi alınarak sayfaların çalışma zamanında hata üretmediği kontrol edilmiştir.

Ekran görüntüleri, canlı çalışan uygulama üzerinden alınmış ve rapordaki şekil açıklamalarıyla birlikte yorumlanmıştır.

Bu doğrulama adımları, raporda sunulan görsellerin ve bulguların statik örneklerden değil, çalışan proje çıktılarından üretildiğini göstermektedir.



EK-F. Alarm İnceleme Kontrol Formu

Alarmın üretildiği metrik adı ve zaman bilgisi kaydedilir.

Aynı zaman aralığında CPU, RAM, ağ, disk ve gecikme metriklerinde paralel bir sapma olup olmadığı kontrol edilir.

Planlı bakım, veri aktarımı, kampanya veya olağan trafik artışı gibi bağlamsal nedenler araştırılır.

Alarmın kullanıcı deneyimine etkisi olup olmadığı istek gecikmesi ve hata kayıtları üzerinden değerlendirilir.

Alarm yanlış pozitif olarak değerlendirilirse model parametresi, pencere uzunluğu veya eşik değeri için iyileştirme notu oluşturulur.

Alarm gerçek olayla ilişkiliyse olay yönetim sürecine aktarılır ve sonraki model güncellemelerinde etiketli örnek olarak kullanılabilir.



EK-G. Uzman Değerlendirmesi Özeti

Geliştirilen erken uyarı sistemi, Doğru Bulut firmasında görev yapan iki sektör profesyoneli tarafından incelenmiştir. Değerlendirme; dashboard ekranı, metrik detay grafikleri, canlı telemetri akışı, alarm listesi, dışa aktarma işlevleri ve erken uyarı mantığının operasyonel karar desteğine katkısı üzerinden yapılmıştır.

Değerlendirici: Murat Poyraz. Akademik/mesleki arka plan: Bilgisayar mühendisliği, bulut sistemleri ve altyapı operasyonları. Mesleki rol: Bulut Sistemleri Mühendisi (Cloud Systems Engineer). Uzmanlık odağı: Cloud operasyonları, hosted exchange, disaster recovery, sanallaştırma ve erken uyarı akışı. Görüş özeti: Prototipin farklı sistem metriklerini birlikte izlemesi, alarm çıktılarının operasyonel inceleme için anlamlı biçimde sunulması ve erken uyarı mantığının cloud izleme süreçlerine uyarlanabilir olması olumlu değerlendirilmiştir.

Değerlendirici: Melih Kutlay. Akademik/mesleki arka plan: Yönetim Bilişim Sistemleri, sistem destek süreçleri ve operasyonel izleme. Mesleki rol: Sistem Destek Uzmanı (System Support Specialist). Uzmanlık odağı: Arayüz kullanılabilirliği, alarm listesi, canlı izleme ekranı ve raporlama/dışa aktarma süreçleri. Görüş özeti: Dashboard yapısının anlaşılır olduğu, alarm kayıtlarının sistem destek süreçlerinde hızlı ön incelemeyi destekleyebileceği, canlı telemetri ekranının operasyon ekipleri tarafından yorumlanabilir olduğu ve dışa aktarma özelliklerinin raporlama açısından fayda sağlayabileceği belirtilmiştir.

Genel sonuç olarak uzman değerlendirmeleri, geliştirilen prototipin anomali tespiti sonuçlarını teknik ekipler için daha izlenebilir, yorumlanabilir ve operasyonel karar desteğine uygun hale getirdiğini göstermektedir.